

PJT Enedis Data Challenge

Aliénor Destribois Thibault Halperin Axel Mannu Léo Pouilly Martin Saulnier
Anis Turki

Arts et Métiers ParisTech

- 1 Introduction
- 2 Pipeline du projet
- 3 Méthodes de reconstruction de valeurs manquantes

- Le compteur Linky collecte quotidiennement les données de consommation électrique de millions d'usagers.
- Enedis utilise ces données pour :
 - l'équilibrage offre/demande,
 - le mécanisme d'ajustement,
 - la facturation réglementée.
- Cependant, des problèmes techniques peuvent entraîner des **trous de données** :
 - pannes locales,
 - erreurs de transmission,
 - défaillances de stockage.

Objectif du challenge

- Enedis fournit **69 000 courbes de consommation synthétiques**, générées avec DeepCoubogen.
- Parmi elles, **1 000 courbes contiennent des données manquantes**.
- Le but est de développer un algorithme capable de :
 - détecter les trous,
 - reconstruire les valeurs manquantes,
 - restituer une série temporelle complète et cohérente.
- Les performances sont évaluées via une **MAE** (Mean Absolute Error) calculée uniquement sur les points manquants.

- **X_train** : 69 000 courbes synthétiques.
- Les 1 000 dernières colonnes sont de la forme `holed_xxxx`, contenant des valeurs manquantes.
- **y_train** : les séries complètes correspondantes, servant de vérité terrain.
- **X_test** : 38 140 séries, dont 1 000 ont des trous à reconstruire.
- Le fichier final doit contenir les 1 000 séries complétées du test.


Exemple d'une colonne X_test et de sa vérité terrain

Horodate	X_test (entrée)	y_train (vérité terrain)
2023-01-09 00 :00	352	352
2023-01-09 00 :30	405	405
2023-01-09 01 :00	NaN	599
2023-01-09 01 :30	315	315
2023-01-09 02 :00	448	448
2023-01-09 02 :30	NaN	373
2023-01-09 03 :00	NaN	385
2023-01-09 03 :30	339	339
2023-01-09 04 :00	NaN	1256
⋮	⋮	⋮
2023-01-09 19 :00	NaN	685
2023-01-09 19 :30	447	447
2023-01-09 20 :00	NaN	479
2023-01-09 20 :30	NaN	542

Pipeline du projet : de l'entraînement à la prédiction

Objectif : apprendre à reconstruire des valeurs manquantes, puis appliquer le processus au jeu de test.

Étape 1 — Entraînement sur les données connues



On apprend à « remplir les trous » sur $X_{\text{train}} \rightarrow Y_{\text{train}}$, puis on applique ce savoir-faire à X_{test} .

1. Interpolation

Principe : relier les points connus pour déduire les valeurs manquantes.

- **Interpolation linéaire** :

$$\hat{x}(t) = x(t_1) + (t - t_1) \frac{x(t_2) - x(t_1)}{t_2 - t_1}$$

- **Splines cubiques** : interpolation lisse par morceaux.
- **Polynômes locaux** : approximation locale d'ordre n .

$$\begin{array}{c} 120 \rightarrow ? \rightarrow 180 \\ \downarrow \\ 120 \rightarrow 150 \rightarrow 180 \end{array}$$

2. Méthodes basées sur la similarité (KNN)

Principe : utiliser des séries complètes ressemblant à la série trouée pour la reconstruire.
Mesure de similarité entre la partie observée x_{obs} et une série complète s_i :

$$\rho(x_{\text{obs}}, s_i) = \frac{\text{COV}(x_{\text{obs}}, s_i)}{\sigma_x \sigma_{s_i}}$$

Reconstruction par moyenne des k séries les plus corrélées :

$$\hat{x}(t) = \frac{1}{k} \sum_{i=1}^k s_i(t)$$

Courbe trouée $\rightarrow$ corrélation $\rightarrow$ voisins proches $\rightarrow$ moyenne

3. Modèles statistiques

Principe : modéliser la relation temporelle interne d'une série pour prédire les valeurs manquantes.

Lissage exponentiel :

$$\hat{x}(t) = \alpha x(t-1) + (1-\alpha)\hat{x}(t-1)$$

ARIMA : modèle autorégressif + intégration + moyenne mobile

$$\phi(B)(1-B)^d x(t) = \theta(B)\varepsilon(t)$$

$$\begin{array}{ccccccc} 120 & \rightarrow & 130 & \rightarrow & 135 & \rightarrow ? & \rightarrow ? \\ & & & & \downarrow & & \\ 120 & \rightarrow & 130 & \rightarrow & 135 & \rightarrow & 138 \rightarrow 141 \end{array}$$

4. Réduction de dimension (PCA / Completion)

Principe : exploiter la structure de faible dimension des séries.

PCA : décomposition en composantes principales

$$X \approx U_k \Sigma_k V_k^\top$$

Matrix completion : reconstruction des valeurs manquantes

$$\min_M \|P_\Omega(X - M)\|^2 \quad \text{avec } \text{rang}(M) \text{ faible}$$

$$[\begin{smallmatrix} ? & 120 & 140 & ? \end{smallmatrix}] \rightarrow \text{faible rang} \rightarrow [\begin{smallmatrix} 110 & 120 & 140 & 145 \end{smallmatrix}]$$

5. Seasonal Decomposition

Principe : décomposer la série en composantes régulières.

$$x(t) = T(t) + S(t) + R(t)$$

Reconstruction d'un trou t :

$$\hat{x}(t) = \hat{T}(t) + \hat{S}(t)$$

avec :

$$\hat{T}(t) = \text{interpolation ou lissage de } T(t)$$

$$\hat{S}(t) = S(t \bmod P)$$

P = période (ex : 48 points = une journée Linky)

6. Matrix Completion (méthodes faible rang)

Principe : compléter une matrice en imposant une structure de faible rang.

Problème d'optimisation :

$$\min_M \|P_\Omega(X - M)\|_F^2$$

Solution typique via SVD tronquée :

$$M \approx U_r \Sigma_r V_r^\top$$

Remplissage des trous :

$$\hat{X}_{ij} = (M)_{ij}$$

7. Kalman Smoothing

Principe : utiliser un modèle d'état dynamique pour estimer les valeurs manquantes.

Modèle :

$$z_t = Az_{t-1} + w_t, \quad x_t = Hz_t + v_t$$

Lissage (forward + backward) :

$$\hat{z}_{t|t} = \hat{z}_{t|t-1} + K_t(x_t - H\hat{z}_{t|t-1})$$

$$\hat{z}_{t|T} = \hat{z}_{t|t} + J_t(\hat{z}_{t+1|T} - \hat{z}_{t+1|t})$$

Reconstruction :

$$\hat{x}(t) = H\hat{z}_{t|T}$$

Synthèse des différentes méthodes

Méthode	Avantages	Inconvénients
Interpolation	Simple, rapide, stable	Ne gère pas les longues zones manquantes
KNN Similarité	Utilise l'information d'autres séries	Dépend fortement des voisins disponibles
Statistiques (ARIMA)	Capture la dynamique temporelle	Modèles sensibles aux ruptures
PCA / Completion	Exploitent la structure globale	Coût calcul élevé, tuning du rang
Seasonal Decomposition	Très adapté aux séries cycliques	Dépend du choix de la période
Kalman Smoothing	Reconstruction optimale gaussienne	Paramétrage du modèle nécessaire